<프로젝트의 방향성>

이번 stage2 이후의 제가 선택한 주제들이 Object Detection, 수식인식기로 CV에 관한 주제들이 남았습니다.

따라서 이번 stage2가 저에게는 NLP에만 초점을 맞추어 진행할 수 있는 유일한 시간이라는 생각으로 깊고 섬세하게 보자는 목표를 잡고 진행하였습니다.

<기술적인 도전>

본인의 점수 및 순위

LB 점수 80.4, 26등

- 진행 과정

- Baseline을 통해 여러 모델을 바꾸어가며 진행 : kobert (acc. 58.8%) etc..
  - Pretrain을 받아오지 못하는 것을 알게되고 pretrain으로 진행시 acc. 71.7%

- Train Data를 들여다보니 영어와 한자 등이 다수 포함 되어있었고, multi-lingual model을 사용해야 겠다는 생각이 들었다.

- Baseline이 하이레벨 api로 구성이 되어있어 커스터마이징하기에 많은 불편함이 있어 relation extraction에 대해서 찾아보았고, R-BERT(https://github.com/monologg/R-BERT, Enriching Pre-trained Language Model with Entity Information for Relation Classification : https://arxiv.org/abs/1905.08284)를 참고하여 모델을 새로 구성하였다.

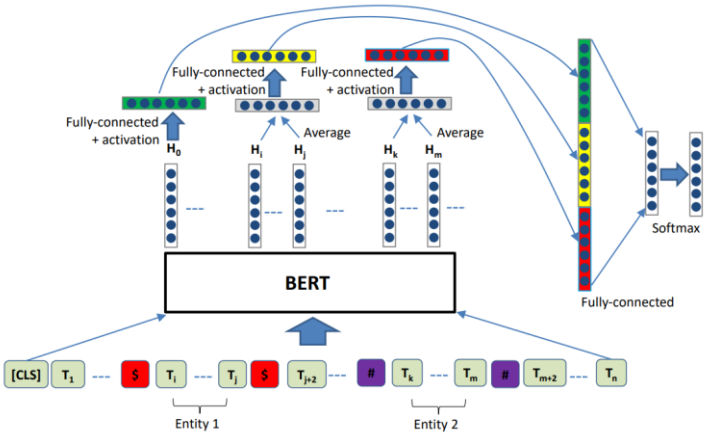

- 모델을 구성하여 학습을 진행하려 했지만 pretrained weight,bias를 상속받아오지 못하는 warning log가 엄청많이 발생하였다.

  - 해결법을 찾으며 코드를 자세히 들여다보다가 BertPretrainedModel class를 상속받아 구현되어진 것을 보고 BertModel class를 상속받아오도록 수정하고 내부적으로 pretrained를 호출하게 구성하여 해결했다.

  - Kobert acc. 73%, XLM-Roberta-large acc. 77.8%

    - Bert계열이 아닌 model적용시 에러가 발생하는 이유가 뭘까?

      - Transformers에서 bertforclassification, electraforclassification 함수의 내부 code를 확인했다.

      - Bert계열은 pooler_output(CLS를 의미), last_hidden_state를 return.

      - Bert가 아닌 계열은 last_hidden_state만 return.

      - 따라서 last_hidden_state[:,0,:]를 통해 CLS임베딩을 뽑아내야 한다.
        - Koelectra acc. 68.6%
        - 이 방식으로 CLS임베딩을 뽑아내면 acc기준 60%후반대의 성능을 보이며 bert계열의 모델보다 크게 성능을 내지 못했다.

  - Maxlen이 어떤 영향을 끼칠까?
    - Train set max len : 345
    - Test set max len : 226
    - Test set max len에 비슷하도록 학습을 진행하면 성능이 좋아지지 않을까?
      - Treain set max len을 250으로 조절
      - R-BERT모델은 Entity가 빠지면 안되므로 250보다 긴 문장은 학습에서 제외 (9000 set -> 8990 set)
      - 결과는 acc기준 77.8% -> 74.2%

  - https://github.com/monologg/R-BERT 에서는 entity layer를 하나만 가지고 두개의 entity가 공유하도록 구성되어진 것을 확인했다.

    - 이 Layer를 나누어 주면 성능이 오르지 않을까?
      - Share acc. 77.8% -> Split acc. 80.4%
      - 이후로는 split layer를 통해 실험이 진행되었다.
      - 하나의 layer로 share하도록 구성되어진 이유가 뭘까?
        - Layer가 늘어나면 GPU메모리가 더 필요하게 된다.
        - 이를 줄여주기위해 이렇게 사용한 것이 아닐까? 하는 예상.

- BERT모델은 GELU activation을 활용하여 학습이 진행되어진다.

  - 그럼 R-BERT에서도 Tanh대신 GELU를 사용하여 activation을 진행하면 어떨까?
    - Tanh Acc. 80.4% -> GELU Acc. 77.0%

- 일반화를 높이기 위해 Cross Entropy loss를 Smooth해서 사용하면 어떨까?
  - https://www.aclweb.org/anthology/2020.emnlp-main.405.pdf

Method	α	EN-DE	EN-CS	EN-FR
Base setup (Vaswani et al., 2017)	—	28.03	21.19	39.66
Token LS (Vaswani et al., 2017; Szegedy et al., 2016)	0.1	28.72	21.47	39.87
Within batch sequence LS (Guo et al., 2018)	0.001	28.81	21.26	39.21
Sampled augmentations BLEU4 (Elbayad et al., 2018)	0.01	29.19	20.94	40.19
BERT+BLEU4	0.1	**29.99**	**22.82**	39.84
BERT+BLEU4	0.01	29.51	22.30	**40.82**

Table 2: BLEU4 evaluation scores on translation tasks from different label smoothing methods. We ran a bootstrap test (Koehn, 2004) for estimating the significance of improvement over the strongest baseline and found that on all three datasets the improvement is statistically significant, $p < 0.05$.

  - 해당 논문을 참고하여 0.05 smoothing을 주어 실험해보았다.
  - Cross Entropy Acc. 80.4% -> Smoothing Acc. 78.5%

- Papers with code(https://paperswithcode.com/sota/relation-extraction-on-semeval-2010-task-8)의 RANK를 보면 R-BERT는 RANK 7을 기록

  - RANK가 높은 모델을 사용하면 더 좋지않을까?

    - RANK4 Skeleton-Aware BERT(Enhancing Relation Extraction Using Syntactic Indicators and Sentential Contexts)가 R-BERT에서 Syntatic Indicators만 적용하면 되는 기술이라 적용하는데에 오래 걸리지 않을 것같다.

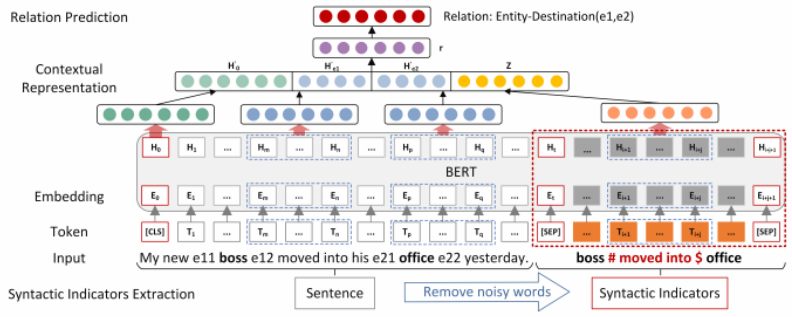

Fig. 2. The overall architecture of the proposed model.

    - Modeling을 끝내고 batch 16으로 학습진행을 하려했지만 layer가 하나 늘어나게 되어 OOM이 발생하였다.

      - 어떻게 해결할까?

        - Batch 16 -> 8로 낮추어 학습 : OOM발생

- FP32를 FP16으로 진행하면 어떨까?
  - FP16으로 적용하게 되면 성능적인 손해가 심할 것 같다.

- U stage에서 배운 최적화 기술 중 쉽게 적용할 수 있는 방법이 있을까?
  - Pytorch 1.6버전에서 내장되어진 FP16과 FP32를 적절히 섞어주는 AMP(Automatic Mixed Precision)을 발견했고, 적용하는데에도 쉬웠다.(https://pytorch.org/docs/stable/notes/amp_examples.html)
  - AMP를 적용하여도 batch 16으로는 진행이 불가하여 batch 8로 진행하였다.
  - Acc. 74.8%

- 모델을 large에서 base로 pretrain모델 성능을 조금 포기하고, model구조의 성능을 통해 올려볼수 있지 않을까?
  - XLM-Roberta-base, batch 8, no AMP : Acc. 75.6%

- R-BERT structure with XLM-Roberta-large Pretrained로 돌아오게 되었다.

- Roberta에 대해 자세히 설명된 글(https://brunch.co.kr/@choseunghyek/7)을 찾았고, batch size가 성능과 완전한 비례관계는 아니지만, 크면 클수록 성능이 좋아지는 경향이 있다고 한다.

  - 토론 게시판에 비슷하게 Batch size에 관한 글이 올라왔고, 작을수록 성능이 좋다는 의견이 있었다.

  - 뭐가 맞을까?
    - Batch 16 Acc. 80.4% -> Batch 8 Acc. 77.7%

- 토론 게시판에 NER tag를 포함한 relation extraction에 대한 글이 올라왔다.

Method	Input Example	$\text{BERT}_{\text{BASE}}$	$\text{BERT}_{\text{LARGE}}$	$\text{RoBERTa}_{\text{LARGE}}$
Entity mask	`[SUBJ-PERSON]` was born in `[OBJ-CITY]`.	69.6	70.6	60.9
Entity marker	`[E1]` Bill `[/E1]` was born in `[E2]` Seattle `[/E2]`.	68.4	69.7	70.7
Entity marker (punct)	@ Bill @ was born in # Seattle #.	68.7	69.8	71.4
Typed entity marker	`[E1-PERSON]` Bill `[/E1-PERSON]` was born in `[E2-CITY]` Seattle `[/E2-CITY]`.	**71.5**	**73.0**	71.0
Typed entity marker (punct)	@ * person * Bill @ was born in # ∧ city ∧ Seattle #.	70.9	72.7	**74.5**

Table 1: **Test F_1 (in %) of different entity representation methods on TACRED.** For each method, we also provide the processed input of an example sentence *"Bill was born in Seattle"*. Typed entity marker (original and punct) significantly outperforms other methods.

  - 오수지님께서 친절하게 special token과 NER tag를 추가한 dataset을 올려주셨다.
    - No NER Acc. 80.4% -> NER tag + NER special token Acc. 78.0%

- NER special token을 빼고 NER tag만 적용하면 어떨까?
  - No NER Acc. 80.4% -> NER tag Acc. 77.9%

- 기존 Train Data에서 잘못 labeling되어진 부분들을 master님께서 수정해서 올려주셨다.

  - No Modify data Acc. 80.4% -> Modify data Acc. 77.5%

  - 10개도안되는 dataset을 바꾸어 적용했는데에 비해 Acc가 너무 크게 감소했다.

  - 이전에 인턴 때 "현대 차 리뷰 긍정/부정/중립 감성분석"을 진행시에도 이와 비슷한 현상이 있었다.

  - Train data에 "역시 현대차는 비싸"와 비슷한 늬앙스의 문장에 대해 담당자님께서 "긍정"이라고 라벨링을 하셨고, 이에 대해 여쭈어 보았다.

  - 당시 현대 차 담당자분께서 브랜드적인 가치가 높게 평가되어지는 것이 현대차 내부에서는 긍정적으로 판단한다는 말씀을 들었고, 크게 생각을 바꿀수 있던 적이 있었다.

  - 지금 Train Data에서도 처음 laber분들께서 labeling할때의 기준에 맞추어 Train, Test labeling이 진행되어졌을 것이고, 시간이 지난 현재 이를 수정한다면 라벨링 당시의 편향에 맞추어지지 않을 것 같아 수정전의 Data로 나머지 실험들은 진행하였다.

- 모델을 개선할 방법을 찾던 중, Sentence-BERT에 관한 글을 발견했다. (https://velog.io/@ysn003/%EB%85%BC%EB%AC%B8-Sentence-BERT-Sentence-Embeddings-using-Siamese-BERT-Networks)

  - 내용이 흥미로워 짧게 읽던 중, 지금 나의 모델에 적용할수 있는 부분을 발견하게 되었다.

  - R-BERT구조에서 CLS, Entity1, Entity2임베딩을 concat하여 Fully Connect Layer를 통과하게 되는데 이 Concat방법을 여러가지로 적용할수 있었다.

	NLI	STSb
Pooling Strategy		
MEAN	**80.78**	**87.44**
MAX	79.07	69.92
CLS	79.80	86.62
Concatenation		
(u, v)	66.04	-
$(\|u - v\|)$	69.78	-
$(u * v)$	70.54	-
$(\|u - v\|, u * v)$	78.37	-
$(u, v, u * v)$	77.44	-
$(u, v, \|u - v\|)$	**80.78**	-
$(u, v, \|u - v\|, u * v)$	80.44	-

- 이에 대해 조원분들과 같이 분석을 진행하였고, 각자 적용해 볼 수있었다.

- 대회 마지막쯔음 발견하게 되어 전부 실험해보기에는 시간이 많이 부족했지만 몇몇개는 실험해 볼 수 있었으며, 결과는 아래의 표에 기록해 두었다.

- Train data에서 라벨 0이 '관계없음'으로 가장 많았고, 내적을 통해 유사도가 0에 가까울수록 관계없음으로 예측을 잘할 것이라는 가설을 바탕으로 내적이 가장 높은 정확도를 보일 것 같았지만 예상과는 다르게 두 임베딩간의 거리가 가장 높은 결과를 보였다.

● 사용한 모델 아키텍처 및 하이퍼 파라미터 (상위 2개)

1. 아키텍처: R-XLMRoberta
    a. LB 점수 : 80.4% (Accuracy)
    b. Base Pretrained Model : XLM-Roberta-large
    c. Hyperparameters
        i. Batch size : 16
        ii. Num labels : 42
        iii. Weight decay : 0.0
        iv. Learning rate : 2e-5
        v. Warmup step : 0
        vi. Max grad norm : 1.0
        vii. Gradient accumulation step : 1
        viii. Dropout rate : 0.1
        ix. Max len : 347
    d. Activation : Tanh
    e. Optimizer : AdamW
    f. Concatenation : (CLS, Entity1, Entity2)

2. 아키텍처: R-XLMRoberta
    a. LB 점수 : 79.0% (Accuracy)

b. Base Pretrained Model : XLM-Roberta-large
c. Hyperparameters
    i. Batch size : 16
    ii. Num labels : 42
    iii. Weight decay : 0.0
    iv. Learning rate : 2e-5
    v. Warmup step : 0
    vi. Max grad norm : 1.0
    vii. Gradient accumulation step : 1
    viii. Dropout rate : 0.1
    ix. Max len : 347
d. Activation : Tanh
e. Optimizer : Adamw
f. Concatenation : (CLS, Entity1, Entity2, | Entity1 - Entity2 |)

- 결과 정리

Entity Layer	Concatenation (e1 : Entity1, e2 : Entity2)	Acc. (%)
Share	(CLS, e1, e2)	77.8
	- Kobert	73.3
	- KoElectra (extract CLS from last_hidden_state)	68.6
	- Maxlen reduce (347 -> 250)	74.2
Split	(CLS, e1, e2)	**80.4**
	- Smooth Cross Entropy	78.5
	- GELU	77.0
	- with NER data	77.9
	- with NER data + NER special token	78.0
	- reduce Batch size (16 -> 8)	77.7
	- with Slack master modify data	77.5
	(CLS, e1, e2, e1*e2)	76.5
	(CLS, e1, e2, |e1-e2|)	79.0
	(CLS*e1, CLS*e2)	76.2
	(CLS*e1, CLS*e2, e1*e2)	76.2

- 앙상블 방법

- 점수적인 면보다는 다양한 실험 결과가 궁금하여 앙상블을 진행하지 못했습니다.

<학습과정에서의 교훈>

- 학습과 관련하여 개인이 얻은 교훈

  - 많은 실험과 자료들을 통해 시야를 크게 넓힐 수 있는 좋은 기회였습니다.

- 피어세션을 진행하며 좋았던 부분과 동료로부터 배운 부분

  - 피어세션을 통해 다양한 시각과 실험결과들을 얻을 수 있었습니다.
  - 위에서 얻은 정보들을 토대로 다양한 가설을 세워 볼 수 있었습니다.
  - 네트워킹이 중요하다는 생각을 다시한번 느꼈습니다.

<마주한 한계와 도전숙제>

- 아쉬웠던 점들

  - 개인적으로 구성한 Validation을 통해 정확도를 체크하는 것 보다 조금더 정확한 결과를 원해 제출을 통해 결과를 확인했지만, 제출기회가 너무 적었습니다.

  - 제출기회도 적었지만, 기간이 짧아 아직 시도해보지 못한 가설들이 많아 아쉽습니다. (ex. R-BERT에서 Entity 임베딩을 위해 구성된 average에 last_hidden_state를 넣어주어 CLS를 뽑아내어 진행하는 실험, 다양한 concatenation 등)

  - Syntatic Indicator를 추가하여 진행하는 실험에서 OOM이 발생하여 AMP를 사용하여 진행할 수 밖에 없던 점이 아쉽습니다.

  - GPU가 조금 더 가능하거나, 좋은 최적화 기술을 구현 할 수 있었다면 NER with NER special token방법 진행시에 NER layer만 따로 추가하여 실험해 볼수도 있었지만, 해보지 못한점이 아쉽습니다.

  - 리더보드 마감 2일전에 2등을 기록하고 있었지만, 앙상블이 시작되면서 최상위권에서 밀려내려온 점도 아쉽습니다.

  - 위와 비슷한 내용이지만 앙상블을 시도해보지 못한점 또한 아쉽습니다.

- 한계/교훈을 바탕으로 다음 스테이지에서 새롭게 시도해볼 것

- 다음 스테이지 부터는 팀 프로젝트로 진행이 되므로 하나의 가설을 세울 때에도 팀원들과 의견을 주고받아 섬세한 가설을 세우도록 시도해볼 것입니다.

- 처음 모델을 구성할때에도 GPU memory적으로도 조금 생각을 해나아가며 줄여볼 수 있을 것 같은 부분들에 대해서는 줄여가며 모델을 구성해 볼 것입니다.